# Skrip Presentasi: Analisis Sentimen Erupsi Gunung Api Indonesia 2021–2025

NER (IndoBERT) dan Rule-Based Sentiment Analysis · 4 pembicara · ±12–13 menit · mengikuti 10 slide pada file PPT final

## Pembagian pembicara

- **Azhar** – Slide 1–3 (pembuka, latar belakang, tujuan), Slide 7 (hasil NER), Slide 9–10 (pembahasan, kesimpulan). ±5 menit
- **Aldani** – Slide 4 dan separuh awal Slide 5 (dataset, pengumpulan data, preprocessing). ±2 menit
- **Sahril** – Separuh akhir Slide 5 dan Slide 6 kiri (anotasi NER, model IndoBERT). ±2,5 menit
- **Naufal** – Slide 6 kanan dan Slide 8 (metode dan hasil sentimen). ±2,5 menit

Teks dalam kurung siku adalah petunjuk dan tidak dibaca. Durasi dihitung ±140 kata per menit.

## Azhar – Pembuka, latar belakang, tujuan

**Slide 1 – Judul**

“Selamat pagi, Bapak dan teman-teman sekalian. Kami dari kelompok Pengolahan Bahasa Alami kelas A akan mempresentasikan proyek berjudul Analisis Sentimen Publik terhadap Erupsi Gunung Api di Indonesia 2021 sampai 2025, menggunakan Named Entity Recognition dan analisis sentimen berbasis aturan. Saya Azhar Aditya Pratama, bertugas di bagian evaluasi. Aldani menjelaskan dataset dan preprocessing, Sahril menjelaskan anotasi dan model NER, Naufal menjelaskan metode dan hasil sentimen, lalu saya kembali untuk hasil NER, pembahasan, dan kesimpulan.”

**Slide 2 – Latar belakang**

“Indonesia berada di Cincin Api Pasifik, sehingga erupsi terjadi hampir setiap tahun. Setiap erupsi memicu banyak video di YouTube, dan penonton menuliskan komentar berupa doa, kritik, pertanyaan, dan informasi lapangan. Komentar ini adalah sumber yang kaya untuk melihat reaksi publik. YouTube kami pilih karena volumenya besar, reaksinya real-time, dan penggunanya beragam. Celah penelitiannya: belum ada analisis yang menggabungkan NER dan sentimen pada komentar erupsi gunung api berbahasa Indonesia.”

**Slide 3 – Tujuan penelitian**

“Tujuan kami ada tiga. Pertama, membangun model NER untuk mengekstrak entitas erupsi seperti gunung, lokasi, bahaya, waktu, pemerintah, dan aktor sosial. Kedua, membangun pipeline sentimen berbasis aturan yang melabeli komentar negatif, netral, atau positif. Ketiga, menganalisis tren sentimen publik pada erupsi tahun 2021 sampai 2025. Untuk dataset dan preprocessing, saya persilakan Aldani.”

## Aldani – Dataset dan preprocessing

**Slide 4 – Dataset**

“Terima kasih, Azhar. Dataset kami berasal dari 335 video YouTube tahun 2021 sampai 2025, yang dikumpulkan dengan yt-dlp. Jumlah videonya 68 pada 2021, 56 pada 2022, 50 pada 2023, 105 pada 2024, dan 56 pada 2025. Dari video tersebut terkumpul 87.840 komentar mentah. Setelah cleaning tersisa 80.239, setelah cleansing 79.524, dan setelah kami ambil kolom judul video, tahun, dan teks bersih, korpus NER kami berjumlah 64.836 komentar. Di bagian bawah slide ada contoh komentar negatif, netral, dan positif.”

**Slide 5 – Pengumpulan dan preprocessing (bagian awal)**

“Preprocessing kami bagi dua tahap. Cleaning menghapus emoji, komentar duplikat, nilai kosong, dan mengubah teks menjadi huruf kecil. Cleansing menyaring 50 komentar spam judi online, menormalisasi slang, memperbaiki typo, serta menyeragamkan ungkapan religius dan negasi. Hasilnya teks yang bersih dan seragam. Selanjutnya Sahril akan menjelaskan anotasi.”

## Sahril – Anotasi dan model NER

**Slide 5 – Anotasi (bagian akhir)**

“Terima kasih, Aldani. Kami mendefinisikan enam jenis entitas dengan format BIO, total 13 label. VOL untuk gunung, misalnya Semeru dan Merapi. LOC untuk lokasi seperti Lumajang. HAZ untuk bahaya seperti awan panas. TIME untuk waktu seperti dini hari. GOV untuk pemerintah seperti PVMBG dan BNPB. SOC untuk aktor sosial seperti pendaki dan relawan.

Menganotasi 64.836 komentar dari nol tidak realistis, jadi kami pakai dua langkah: pre-anotasi otomatis dengan kamus frasa, lalu verifikasi manual di Label Studio. Sebanyak 18.537 komentar, atau 28,6 persen, dianotasi manual. Hasilnya diselaraskan ke token IndoBERT berdasarkan posisi karakter, sehingga setiap token punya label BIO.”

**Slide 6 – Model NER**

“Model yang kami pakai adalah IndoBERT base p1, yang sudah dilatih pada teks berbahasa Indonesia, lalu kami fine-tune untuk token classification dengan 13 label BIO. Data dibagi menjadi 55.101 record untuk latih, 3.054 untuk validasi, dan 6.681 untuk test. Pelatihan berjalan 5 epoch dengan learning rate 3e-5 dan batch 16. Kami mengevaluasi dengan precision, recall, dan F1 per entitas, memakai validasi untuk memilih model dan test sebagai evaluasi akhir. Untuk metode sentimen, saya persilakan Naufal.”

## Naufal – Metode dan hasil sentimen

**Slide 6 – Metode sentimen**

“Terima kasih, Sahril. Untuk sentimen kami memakai pipeline berbasis aturan. Isinya lebih dari 300 entri leksikon bahasa Indonesia, penanganan negasi, deteksi ungkapan doa dan religius, serta penyaringan spam. Setiap komentar mendapat label, skor kepercayaan, jejak aturan, dan penanda perlu ditinjau. Labelnya 0 negatif, 1 netral, dan 2 positif. Untuk mengukur akurasi, kami menyusun gold standard manual: 120 baris dev dan 120 baris holdout.”

[Naufal menyerahkan ke Azhar untuk Slide 7, lalu kembali untuk Slide 8.]

**Slide 8 – Hasil sentimen**

“Dari 64.836 komentar, 57,9 persen netral, 31,2 persen positif, dan 10,9 persen negatif. Komentar netral banyak karena isinya fakta, pertanyaan, atau spam dan off-topic. Positif berisi doa, pujian, dan terima kasih. Per tahun, 2023 punya volume tertinggi, 20.567 komentar, bertepatan dengan erupsi Marapi, dan jumlah komentar negatif tertinggi, 3.035. Akurasi pada gold standard 84,17 persen untuk dev dan 85,00 persen untuk holdout, sehingga kinerjanya stabil. Selanjutnya Azhar membahas kesimpulan.”

## Azhar – Hasil NER, pembahasan, kesimpulan

**Slide 7 – Hasil NER** [dibacakan setelah Slide 6, sebelum Naufal membahas Slide 8]

“Terima kasih, Naufal. Hasil NER kami: F1 mikro pada validasi 98,89 persen, dan pada test set, yang menjadi evaluasi utama, 97,83 persen dengan 2.201 entitas. Per entitas pada test: SOC tertinggi dengan F1 0,9941, lalu VOL 0,9842, LOC 0,9673, GOV 0,9514, TIME 0,9500, dan HAZ terendah 0,9333. HAZ terendah karena hanya 64 kemunculan, dan precision-nya 0,8873 lebih rendah dari recall 0,9844, artinya model cukup sering salah menambah label HAZ. Selisih validasi dan test sekitar satu poin, jadi tidak ada tanda overfitting.”

**Slide 9 – Pembahasan dan Knowledge Graph**

“Ada tiga temuan utama. Pertama, kelas dengan data banyak seperti SOC dan VOL hampir sempurna, sedangkan HAZ dengan data paling sedikit paling lemah. Kedua, pola sentimen mencerminkan budaya publik: tradisi doa menghasilkan sentimen positif tinggi, dan pemberitaan fakta menghasilkan netral dominan. Ketiga, grafik ko-okurensi entitas dari 10.000 komentar teranotasi menunjukkan gunung, lokasi, dan aktor sosial sering muncul bersama, misalnya Semeru dengan Lumajang dan pengungsi. Ini masih prototipe visualisasi.”

**Slide 10 – Kesimpulan dan pekerjaan lanjutan**

“Kesimpulannya, NER kuat di semua enam entitas dengan F1 mikro test 97,83 persen. Sentimen berbasis aturan mencapai akurasi 85 persen pada holdout, dan sentimen publik didominasi netral dan positif. Keterbatasannya: label awal berasal dari kamus frasa, gold standard sentimen hanya 240 baris, dan support HAZ kecil. Pekerjaan lanjutan: classifier sentimen berbasis IndoBERT, anotasi yang lebih besar, dan data lintas platform. Terima kasih, kami siap menerima pertanyaan.”

## Antisipasi pertanyaan

- **Skor NER terlalu tinggi, apakah overfitting?** Selisih validasi (98,89%) dan test (97,83%) hanya sekitar satu poin, jadi tidak ada tanda overfitting. Namun label awal berasal dari kamus, sehingga model perlu diuji pada komentar di luar kamus.
- **Mengapa HAZ paling rendah?** Support hanya 64, dan ekspresinya beragam. Penyebab pasti menunggu analisis error.
- **Mengapa sentimen memakai aturan, bukan model?** Tidak ada data berlabel sentimen yang cukup besar. Aturan memberi jejak yang bisa ditelusuri, dan classifier IndoBERT menjadi pekerjaan lanjutan.
- **Mengapa mayoritas netral?** Banyak komentar berisi fakta, pertanyaan, atau spam dan off-topic.
- **Mengapa memilih IndoBERT?** Sudah dilatih pada teks berbahasa Indonesia dan mendukung token classification.

## Catatan sebelum rekaman

- Urutan bicara mengikuti urutan slide: Slide 7 (Azhar) berada di antara Slide 6 (Naufal) dan Slide 8 (Naufal). Bila ingin lebih lancar, pindahkan Slide 7 setelah Slide 8 pada file PPT.
- Pembahasan tren per tahun bisa dipotong bila waktu mepet; angka Slide 8 tetap perlu disebut.
- Konfigurasi learning rate 3e-5 dan batch 16 berasal dari skrip lama; pastikan sesuai notebook pelatihan.